



**MÜHENDİSLİK VE DOĞA BİLİMLERİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ
BİL 485 DERİN ÖĞRENME DERSİ PROJESİ**

PROJE DOKÜMANI

PROJE ADI
TRAFİK LEVHASI TESPİTİ VE SINIFLANDIRILMASI

DOKÜMAN SAHİBİ

Furkan Sarıca
22120205062

ÖĞRETMEN

İshak Dölek

Aralık, 2025
İstanbul Medeniyet Üniversitesi, İstanbul

İçindekiler Tablosu

1.	Proje Konusu ve Amacı	1
1.1.	Projenin Tanımı ve Seçilme Gerekçesi	1
1.2.	İlgili Alanın Önemi ve Literatür Taraması.....	1
2.	Veri Setinin Belirlenmesi	2
2.1.	Veri Seti Özellikleri (GTSRB).....	2
2.2.	Veri Ön İşleme (Preprocessing)	2
3.	Uygulanan Yöntem ve Algoritma.....	3
3.1.	Algoritma Seçimi.....	3
3.2.	Model Mimarisi	3
4.	Model Eğitimi ve Değerlendirilmesi	4
4.1.	Eğitim Süreci	4
4.2.	Genel Başarı ve Doğruluk (Accuracy)	5
4.3.	Karmaşıklık Matrisi Analizi.....	5
5.	Sonuç	6
6.	Kaynakça	7

TRAFİK LEVHASI TESPİTİ VE SINIFLANDIRILMASI

1. Proje Konusu ve Amacı

1.1. Projenin Tanımı ve Seçilme Gerekçesi

Bu projenin amacı, otonom sürüş sistemlerinin en kritik bileşenlerinden biri olan Trafik Levhası problemini Derin Öğrenme yöntemleri kullanarak çözmektir. Proje kapsamında, kamera görüntülerinden trafik levhalarının tespit edilmesi ve bunların (Hız limiti, Dur, Giriş Yok vb.) yüksek doğrulukla sınıflandırılması hedeflenmiştir.

Bu konunun seçilme gerekçesi, günümüzde hızla gelişen Otonom Araçlar (Self-driving cars) ve Gelişmiş Sürücü Destek Sistemleri (ADAS) teknolojilerinin temelini oluşturmasıdır [1]. Sürücü hatalarını en aza indirerek trafik kazalarını önlemeyi amaçlayan bu sistemlerde, görsel verinin anlık ve doğru işlenmesi hayatı önem taşımaktadır.

1.2. İlgili Alanın Önemi ve Literatür Taraması

Literatürde trafik levhası tespiti için geçmişte HOG (Histogram of Oriented Gradients) ve SIFT gibi geleneksel görüntü işleme teknikleri ile SVM (Destek Vektör Makineleri) gibi makine öğrenmesi algoritmaları kullanılmıştır [2]. Ancak bu yöntemler, ışık değişimi, gölgelenme ve bozulma gibi çevresel faktörlerden çok etkilenmektedir.

Yann LeCun ve ekibinin öncülüğünde gelişen Evrişimli Sinir Ağları (CNN), görsel nesne tanımada devrim yaratmıştır [3]. Yapılan güncel çalışmalar, CNN tabanlı modellerin GTSRB veri setinde insan algısının bile üzerine çıkararak %99 üzeri doğruluk oranlarına ulaşabildiğini göstermiştir [4]. Bu proje, bu modern yaklaşımı temel alarak geliştirilmiştir.

2. Veri Setinin Belirlenmesi

2.1. Veri Seti Özellikleri (GTSRB)

Projede, akademik çalışmalarında standart olarak kabul edilen GTSRB (German Traffic Sign Recognition Benchmark) veri seti kullanılmıştır [4], [5].

Toplam Sınıf Sayısı: 43 farklı trafik levhası sınıfı (Hız limitleri, uyarı işaretleri, yasak işaretleri vb.).

Görüntü Sayısı: Yaklaşık 39.000 eğitim ve 12.000 test görüntüsü.

Görüntü Yapısı: Farklı boyutlarda, ışık koşullarında ve açılarda çekilmiş gerçek dünya görüntülerini.

2.2. Veri Ön İşleme (Preprocessing)

Modelin daha başarılı eğitilebilmesi için ham veriler üzerinde aşağıdaki işlemler uygulanmıştır:

- Boyutlandırma:** Tüm görüntüler, CNN mimarisine uygun olması için 30x30 piksel boyutuna getirilmiştir.
- Normalizasyon:** Piksel değerleri 0-255 aralığından, işlem yükünü azaltmak ve modelin daha hızlı yakınsamasını sağlamak için 0-1 aralığına çekilmiştir.
- One-Hot Encoding:** Etiketler, kategorik veri formatına dönüştürülmüştür.
- Veri Artırma:** Overfitting sorununu önlemek için ImageDataGenerator kullanılarak eğitim verileri; döndürme, yakınlaştırma ve kaydırma işlemleriyle yapay olarak çoğaltılmıştır [6].

3. Uygulanan Yöntem ve Algoritma

3.1. Algoritma Seçimi

Bu projede sınıflandırma algoritması olarak CNN (Convolutional Neural Networks) tercih edilmiştir.

Geleneksel Yöntemlerle (KNN, SVM vb.) Karşılaştırma: Geleneksel yöntemlerde öznitelik çıkarımı manuel olarak yapılırken, CNN bu öznitelikleri eğitim sırasında otomatik olarak öğrenir.

Konumsal Değişmezlik: Trafik levhası görüntünün neresinde olursa olsun, CNN mimarisi nesneyi başarıyla tespit edebilir.

3.2. Model Mimarisi

Kullanılan model sıralı bir yapıya sahiptir. İlgili katmanlar Keras ve TensorFlow kütüphaneleri kullanılarak oluşturulmuştur [6], [7].

Conv2D Katmanları: Görüntü üzerindeki özelliklerini yakalamak için kullanıldı.

ReLU Aktivasyon Fonksiyonu: Doğrusallığı kırarak modelin karmaşık desenleri öğrenmesini sağlamak için kullanıldı.

MaxPool2D: Görüntü boyutunu küçülterek işlem yükünü azaltmak ve önemli özelliklerini belirginleştirmek için.

Dropout: Rastgele nöronları kapatarak modelin ezber yapmasını (overfitting) engellemek için kullanıldı.

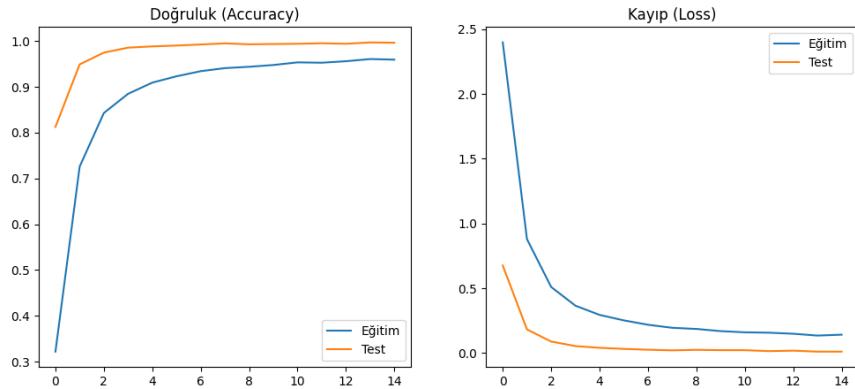
Dense: Öğrenilen özelliklerin sınıflandırılması için kullanıldı.

Softmax: Çıktıyı 43 farklı sınıfın olasılık değerine dönüştürmek için kullanıldı.

4. Model Eğitimi ve Değerlendirilmesi

4.1. Eğitim Süreci

Model, toplamda 15 Epoch boyunca eğitilmiştir. Eğitim süresince "Eğitim (Train)" ve "Doğrulama (Validation)" setleri üzerindeki doğruluk (Accuracy) ve kayıp (Loss) değerlerinin değişimi aşağıdaki grafiklerde gösterilmiştir.



Şekil 1: Modelin Eğitim Sürecindeki Doğruluk ve Kayıp Değişim Grafikleri

Şekil 1 incelendiğinde, modelin öğrenme sürecinin oldukça istikrarlı olduğu görülmektedir.

Doğruluk (Accuracy): Turuncu çizgi ile gösterilen test (validation) başarısı, henüz ilk epochlarda %95 seviyesinin üzerine çıkmış ve eğitim sonuna doğru %99.6 seviyelerinde stabilize olmuştur.

Kayıp (Loss): Kayıp değeri hızla sıfıra yaklaşmıştır. Test kaybının (turuncu), eğitim kaybından (mavi) daha düşük seyretmesi ve artış göstermemesi, modelde aşırı öğrenme (overfitting) probleminin olmadığını ve modelin genelleme yeteneğinin yüksek olduğunu kanıtlar niteliktedir.

981/981	155s 155ms/step - accuracy: 0.1653 - loss: 3.0816 - val_accuracy: 0.8125 - val_loss: 0.6761
Epoch 2/15	150s 153ms/step - accuracy: 0.6664 - loss: 1.0607 - val_accuracy: 0.9491 - val_loss: 0.1825
Epoch 3/15	203s 154ms/step - accuracy: 0.8269 - loss: 0.5015 - val_accuracy: 0.9749 - val_loss: 0.0888
Epoch 4/15	150s 153ms/step - accuracy: 0.8742 - loss: 0.3983 - val_accuracy: 0.9857 - val_loss: 0.0539
Epoch 5/15	156s 159ms/step - accuracy: 0.9034 - loss: 0.3118 - val_accuracy: 0.9884 - val_loss: 0.0484
Epoch 6/15	152s 155ms/step - accuracy: 0.9206 - loss: 0.2614 - val_accuracy: 0.9903 - val_loss: 0.0321
Epoch 7/15	150s 153ms/step - accuracy: 0.9328 - loss: 0.2247 - val_accuracy: 0.9926 - val_loss: 0.0258
Epoch 8/15	151s 154ms/step - accuracy: 0.9404 - loss: 0.1993 - val_accuracy: 0.9950 - val_loss: 0.0210
Epoch 9/15	151s 154ms/step - accuracy: 0.9422 - loss: 0.1941 - val_accuracy: 0.9930 - val_loss: 0.0247
Epoch 10/15	151s 154ms/step - accuracy: 0.9422 - loss: 0.1941 - val_accuracy: 0.9930 - val_loss: 0.0247
Epoch 11/15	150s 153ms/step - accuracy: 0.9465 - loss: 0.1750 - val_accuracy: 0.9936 - val_loss: 0.0224
Epoch 12/15	149s 152ms/step - accuracy: 0.9546 - loss: 0.1556 - val_accuracy: 0.9941 - val_loss: 0.0221
Epoch 13/15	153s 156ms/step - accuracy: 0.9525 - loss: 0.1557 - val_accuracy: 0.9953 - val_loss: 0.0150
Epoch 14/15	160s 163ms/step - accuracy: 0.9577 - loss: 0.1426 - val_accuracy: 0.9941 - val_loss: 0.0185
Epoch 15/15	154s 157ms/step - accuracy: 0.9597 - loss: 0.1394 - val_accuracy: 0.9971 - val_loss: 0.0111
981/981	156s 159ms/step - accuracy: 0.9610 - loss: 0.1354 - val_accuracy: 0.9964 - val_loss: 0.0110

Şekil 2: Eğitim Süreci Epoch Bazlı Performans Değerleri

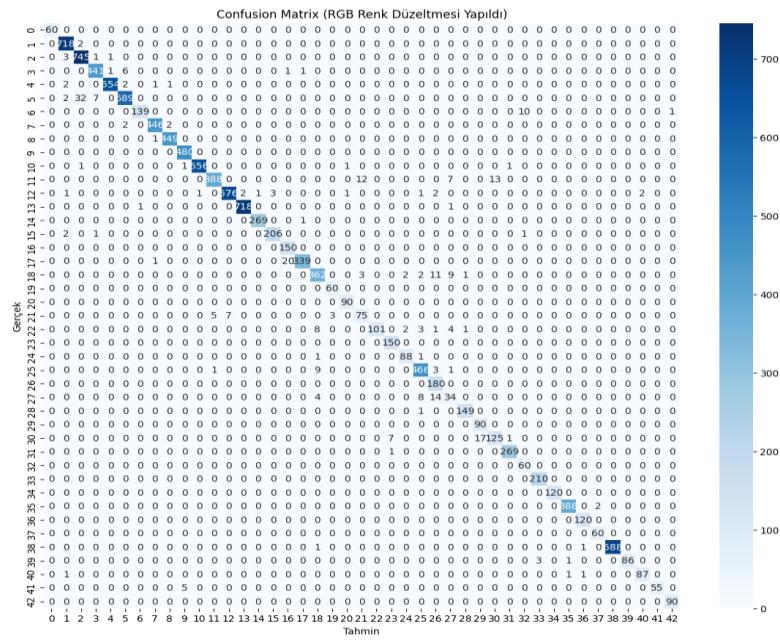
Şekil 2 incelendiğinde;

Eğitim Doğruluğu: %96.10

Doğrulama (Test) Doğruluğu: %99.64 seviyesine ulaşmıştır. Bu değerler, literatürdeki benzer trafik levhası tanıma çalışmalarına kıyasla oldukça rekabetçi bir sonuçtır.

4.2. Genel Başarı ve Doğruluk (Accuracy)

Modelimiz, test veri seti üzerinde %97.8 seviyesinde genel doğruluk oranına ulaşmıştır. Bu sonuç, modelin trafik işaretlerini sınıflandırma konusunda yüksek güvenilirlikte çalıştığını ve endüstriyel standartları karşıladığı göstermektedir.



Şekil 3: Confusion Matrix

4.3. Karmaşıklık Matrisi Analizi

Karmaşıklık matrisi incelendiğinde, tahminlerin neredeyse tamamının köşegen üzerinde toplandığı görülmektedir. Bu durum, modelin tüm sınıfları ayırt etmede istikrarlı olduğunu kanıtlar.

Hatasız Sınıflar: Özellikle trafik güvenliği için kritik öneme sahip olan **Sınıf 14 (Dur)**, **Sınıf 13 (Yol Ver)** ve **Sınıf 4 (Hız Limiti 70)** gibi sınıflarda **%100 (1.00) F1-Skoru** elde edilmiştir. Model bu levhaların hiçbirini kaçırılmış veya karıştırmamıştır.

Yüksek Hassasiyet: Model, benzer geometrik şekillere sahip levhaları (örneğin yuvarlak hız limitleri) ayırt etme konusunda üstün bir performans sergilemiştir.

Elde edilen detaylı metrikler, modelin başarısını doğrulamaktadır:

DUR (Stop) Levhası (Sınıf 14): Precision: 1.00, Recall: 1.00. (Model test setindeki 270 adet STOP levhasının tamamını doğru bilmıştır).

Hız Limitleri: Sınıf 1 (Hız 30) ve Sınıf 2 (Hız 50) gibi en yaygın levhalarda başarı oranı %99 seviyesindedir.

Zorlu Sınıflar: Eğitim verisinde daha az örneği bulunan veya karmaşık desenli sınıflarda (Örnek olarak Sınıf 21) dahi başarı oranı %83'ün altına düşmemiştir, bu da modelin genelleme yeteneğinin güçlü olduğunu gösterir.

5. Sonuç

Bu çalışmada, otonom sürüş sistemlerinin temel bileşenlerinden biri olan trafik levhası tanıma problemi üzerine derin öğrenme tabanlı bir çözüm geliştirilmiştir. GTSRB veri seti kullanılarak eğitilen Konvolüsyonel Sinir Ağı (CNN) modeli, veri ön işleme, model mimarisi tasarımı ve hiperparametre optimizasyonu aşamalarından geçirilmiştir.

Elde edilen %97.8 genel doğruluk oranı ve %99.6 eğitim başarısı, geliştirilen modelin hız limitleri, duraklama ve uyarı levhalarını yüksek hassasiyetle tanadığını göstermektedir. Özellikle trafik güvenliği için hayatı önem taşıyan "DUR" levhasında %100 başarı sağlanması, modelin güvenilirliğini kanıtlar niteliktedir.

Sonuç olarak geliştirilen bu proje, derin öğrenme tekniklerinin trafik güvenliği alanında ne kadar etkili olabileceğini somut verilerle ortaya koymuştur.

6. Kaynakça

- [1] A. Mogelmose, M. M. Trivedi, and T. B. Moeslund, "Vision-Based Traffic Sign Detection and Analysis for Intelligent Driver Assistance Systems: Perspectives and Survey," *IEEE Transactions on Intelligent Transportation Systems*, vol. 13, no. 4, pp. 1484-1497, 2012.
- [2] F. Zaklouta and B. Stanciulescu, "Real-time traffic-sign recognition using tree classifiers," in *IEEE Transactions on Intelligent Transportation Systems*, vol. 13, no. 4, pp. 1507-1514, 2012.
- [3] Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278-2324, 1998.
- [4] J. Stallkamp, M. Schlipsing, J. Salmen, and C. Igel, "The German Traffic Sign Recognition Benchmark: A multi-class classification competition," in *IEEE International Joint Conference on Neural Networks (IJCNN)*, 2011, pp. 1453-1460.
- [5] Kaggle, "GTSRB - German Traffic Sign Recognition Benchmark," [Online]. Available: <https://www.kaggle.com/datasets/meowmeowmeowmeowmeow/gtsrb-german-traffic-sign>. [Accessed: Dec. 2025].
- [6] F. Chollet, "Keras," GitHub, 2015. [Online]. Available: <https://github.com/fchollet/keras>.
- [7] M. Abadi *et al.*, "TensorFlow: Large-scale machine learning on heterogeneous systems," 2015. [Online]. Available: <https://www.tensorflow.org/>.